

Zaawansowane Metody Akwizycji, Preprocessingu i Dyskretnej Reprezentacji Sygnałów EEG: Od Bezprzewodowych Systemów Aktywnych po Fundacyjne Modele Generatywne i Integrację Wielomodalną

Wprowadzenie do Nowoczesnej Neuroinformatyki i Wyzwań Akwizycji Danych

Dynamiczny rozwój neuroinformatyki oraz bezinwazyjnych interfejsów mózg-komputer (BCI – Brain-Computer Interfaces) jest obecnie napędzany przez bezprecedensową konwergencję dwóch niezależnych dotąd dziedzin: mobilnych technologii sprzętowych o wysokiej precyzji oraz zaawansowanych architektur głębokiego uczenia maszynowego (Deep Learning). Tradycyjne, kliniczne metody elektroencefalografii (EEG) wiązały się z bezwzględną koniecznością stosowania żeli lub past przewodzących, a także rygorystycznego ścierania naskórka w celu obniżenia impedancji kontaktowej. Te inwazyjne procedury przygotowawcze drastycznie ograniczały użyteczność systemów BCI wyłącznie do sterylnych, kontrolowanych warunków laboratoryjnych. Współczesne paradygmaty badawcze – obejmujące takie domeny jak neuroergonomia, neuromarketing, analiza obciążeń kognitywnych w wirtualnej rzeczywistości (VR) czy długoterminowe monitorowanie pacjentów neurologicznych – przenoszą się jednak bezpośrednio do środowisk naturalnych.¹ Wymaga to wdrożenia sprzętu w pełni odpornego na artefakty ruchowe (ambulation artifacts) oraz zakłócenia elektromagnetyczne.³

Jednocześnie, wraz ze wzrostem dostępności przenośnych urządzeń rejestrujących, badacze stają w obliczu fundamentalnego problemu analitycznego. Analiza generowanych przez sprzęt EEG wielowymiarowych i wysoce niestacjonarnych szeregów czasowych stanowi potężne wyzwanie obliczeniowe, którego nie są w stanie skutecznie zrealizować proste modele statystyczne. Złożoność układów bioelektrycznych, bardzo niska wartość stosunku sygnału do szumu (SNR – Signal-to-Noise Ratio), zanikający charakter sygnału przy przejściu przez warstwy opon mózgowych i czaszkę, a także ogromna zmienność międzyosobnicza (inter-subject variability) sprawiają, że klasyczne algorytmy inżynierii cech czy proste sieci konwolucyjne napotykają na barierę skalowalności.⁵

Odpowiedzią na ten kryzys informacyjny staje się integracja najnowocześniejszych systemów sprzętowej akwizycji (takich jak systemy z aktywnymi elektrodami suchymi) z fundamentalnymi

modelami generatywnymi. Szczególną rolę odgrywają tu architektury oparte na wektorowej kwantyzacji, w tym Vector Quantized Variational Autoencoder (VQ-VAE). Techniki te pozwalają na rzutowanie ciągłych, niestabilnych i silnie zaszumionych sygnałów o wysokiej rozdzielczości czasowej na dyskretne przestrzenie ukryte (latent spaces).⁸ Proces ten tworzy skwantyzowany "słownik" motywów neuronalnych, który skutecznie odfiltruje stochastyczny szum fizjologiczny i techniczny. Dyskretyzacja sygnału EEG nie tylko redukuje problem zmienności między poszczególnymi sesjami czy pacjentami, ale również stanowi niezwykle wydajny, uniwersalny interfejs umożliwiający bezpośrednią współpracę szeregów czasowych EEG z potężnymi dużymi modelami językowymi (Large Language Models – LLM) oraz wizyjnymi. Takie podejście otwiera drogę do rewolucyjnych rozwiązań, jak na przykład wysokotrafna translacja myśli i intencji na tekst w czasie rzeczywistym.¹¹

Analiza dostępnych danych empirycznych i literaturowych wykazuje precyzyjną ścieżkę ewolucyjną sygnału: począwszy od tego, jak surowe szeregi czasowe przechodzą przez proces wewnątrzsprzętowej preamplifikacji, poprzez rygorystyczną kontrolę impedancji i cyfrową interpolację programową, aż po zasilanie wysokopoziomowych potoków (pipelines) głębokiego uczenia. Co więcej, wgląd w ekosystem społeczności open-source ukazuje, że zaawansowane koncepcje – takie jak rzadkie kodowanie w architekturze AtomVQVAE czy harmonizacja wielomodalnych zbiorów treningowych – skutecznie demokratyzują technologie BCI, przenosząc wysoce wyspecjalizowane metodologie na platformy ogólnodostępne.⁷

Architektura Elektrofizjologiczna i Sprzętowa Systemu Wearable Sensing DSI-24

Determinantem sukcesu wszelkich zaawansowanych sieci głębokich w neuroinformatyce jest jakość i wiarygodność danych zasilających pierwszą warstwę wejściową modelu. Pod tym względem system Wearable Sensing DSI-24 pozycjonuje się jako sprzęt klasy referencyjnej (research-grade), który całkowicie redefiniuje standardy mobilnej elektroencefalografii.

Architektura urządzenia odchodzi od konwencjonalnych sensorów na rzecz technologii aktywnych elektrod suchych (Dry Sensor Interface). Elektrody te zostały zaprojektowane tak, aby skutecznie penetrować powłokę włosów i nawiązywać kontakt ze skórą głowy bez konieczności ablacji naskórka czy stosowania jakichkolwiek żeli redukujących impedancję.³

System DSI-24 rejestruje sygnały przy użyciu 24 kanałów o rozdzielczości 16 bitów każdy, z których 21 odpowiada rozmieszczeniu zgodnemu z rozszerzonym międzynarodowym systemem 10-20. Topologia kanałów obejmuje elektrody: Fp1, Fp2, Fz, F3, F4, F7, F8, Cz, C3, C4, T7/T3, T8/T4, Pz, P3, P4, P7/T5, P8/T6, O1, O2, A1 oraz A2.¹ Ponadto urządzenie jest wyposażone w 3 dedykowane wejścia pomocnicze (auxiliary inputs), które umożliwiają symultaniczną rejestrację dodatkowych sygnałów peryferyjnych w konfiguracji monopolarnej lub bipolarnej, takich jak elektrookulogram (EOG), elektromiogram (EMG), elektrokardiogram (ECG) czy reakcja skórno-galwaniczna (GSR).² Całość układu pomiarowego korzysta z referencji zaimplementowanej w oparciu o architekturę "Common Mode Follower" ze zintegrowanym uziemieniem, zlokalizowanym na pozycji Fpz, co stanowi kluczowy element stabilizacji linii bazowej sygnału.¹

Fundamentalnym problemem i technologicznym wyzwaniem w elektroencefalografii opartej na elektrodach suchych jest zjawisko ogromnej, stochastycznie zmiennej impedancji kontaktu na granicy elektroda-skóra. W systemach pasywnych zjawisko to prowadzi do drastycznego tłumienia napięcia mikrowoltowego sygnału mózgowego i potęguje jego podatność na zewnętrzne zakłócenia elektromagnetyczne (w tym na artefakty pochodzące z sieci energetycznej 50/60 Hz oraz zakłócenia kapacytywne). Inżynierowie Wearable Sensing rozwiązali ten problem poprzez zastosowanie precyzyjnych wzmacniaczy operacyjnych o ultra-wysokiej impedancji wejściowej, wynoszącej 47 GΩ.² Ten nieprawdopodobnie wysoki bufor gwarantuje niemal bezstratną transmisję potencjału z powierzchni skóry, nawet w sytuacjach, gdy kontakt fizyczny jest bardzo słaby, a lokalna impedancja bariery rogowej ulega drastycznym zmianom.

Wysoka impedancja wejściowa układu jest wspierana przez bezprecedensowy współczynnik tłumienia sygnału wspólnego (CMRR – Common Mode Rejection Ratio), który przekracza 120 dB.¹ Urządzenie posiada również parametry minimalizujące zakłócenia układu analogowego: prąd polaryzacji wejścia (Input Bias Current) kształtuje się poniżej 25 pA, natomiast tolerancja na niezrównoważenie stałoprądowe (DC Offset Tolerance) obejmuje zakres ±200 mV przy maksymalnym zakresie wejściowym 10 mV p-p.³ Taka izolacja elektrofizjologiczna – połączona z fizycznym aktywnym i pasywnym ekranowaniem wewnątrz każdego z sensorów na kształt klatki Faradaya – skutkuje zachowaniem poziomu szumu w przedziale częstotliwości 1-50 Hz na poziomie niższym niż 3 μV p-p (lub <1 μV RMS).² W niezależnych badaniach wykazano, że sygnał pochodzący z elektrod suchych DSI wykazuje ponad 90% korelacji morfologicznej z tradycyjnymi, uciążliwymi w użyciu systemami mokrymi klasy referencyjnej, co ostatecznie znosi potrzebę kompromisu pomiędzy mobilnością a rygorem naukowym.²

Sygnał analogowy w systemie DSI-24 próbkowany jest natywnie z częstotliwością 300 Hz, choć producent przewidział możliwość programowej aktualizacji urządzenia do trybu 600 Hz.¹ Zastosowanie 16-bitowego przetwornika A/D przekłada się na efektywną rozdzielczość pomiarową rzędu 0.317 μV w odniesieniu do wejścia sprzętowego.¹ Tak szeroka dynamika układu pomiarowego jest krytyczna dla bezbłędnej rejestracji submikrowoltowych fluktuacji wchodzących w skład potencjałów wywołanych (ERP) oraz wolnych potencjałów korowych, które mieszczą się w natywnym paśmie przepustowym sprzętu wynoszącym od 0.003 do 150 Hz.¹ Transmisja zarejestrowanych, wysoce wzmocnionych i zdigitalizowanych danych odbywa się za pomocą standardu Bluetooth o zasięgu do 10 metrów (w linii wzroku), co we współpracy z akumulatorami zapewniającymi ponad 24 godziny pracy, stwarza nieograniczone możliwości prowadzenia długofalowych eksperymentów w swobodnym poruszaniu się pacjenta.¹ W tabeli 1 zestawiono najbardziej kluczowe parametry techniczne systemu DSI-24, które wpływają na strukturę i charakterystykę danych wejściowych zasilających w kolejnych etapach algorytmu uczenia maszynowego.

Parametr Techniczny	Specyfikacja	Interpretacja i Znaczenie dla Głębokich Modeli Analitycznych

Topologia Kanałów EEG	21 elektrod (System 10-20) + Fpz (GND)	Ujednolicone i standaryzowane pokrycie kory mózgowej, kluczowe dla przestrzennych sieci CNN i modeli transformatorowych. ³
Peryferia (Auxiliary)	3 wejścia (X1, X2, X3) + 8-bit TTL	Fuzja wielomodalna; możliwość precyzyjnej rejestracji sygnałów fizjologicznych (np. EKG) synchronizowanych zdarzeniami. ¹
Impedancja Wejściowa	47 GΩ	Pasywna obrona przed utratą sygnału wywołaną fluktuującą jakością kontaktu suchych elektrod ze skórą pacjenta. ²
Współczynnik CMRR	> 120 dB	Eliminacja zewnętrznych pól interferencyjnych (50/60 Hz), co zmniejsza zapotrzebowanie na agresywną filtrację w fazie preprocessingu. ¹
Próbkowanie i Rozdzielczość	300/600 Hz, 16 bitów, 0.317 μV	Przechwytywanie pełnego profilu widmowego (od pasm Delta do Gamma) przy zachowaniu precyzji zapobiegającej nasyceniu przetworników. ¹
Zasilanie i Mobilność	Bateria >24h, Bluetooth 10m	Umożliwienie weryfikacji skuteczności BCI w chaotycznym świecie rzeczywistym, generowanie zróżnicowanych zestawów danych treningowych. ¹

Oprócz doskonałości układów wewnętrznych, fizyczna konstrukcja czepka i samych elektrod stanowi istotny element redukcji artefaktów. Elektrody DSI-24 mają formę sprężynujących wypustek, które automatycznie adaptują się do krzywizny czaszki badanej osoby, utrzymując stały, komfortowy docisk.² W konsekwencji system ten minimalizuje przesunięcia przestrzenne elektrod wywołane krokami, gwałtownym ruchem czy rotacją głowy (ambulation artifacts). Szybkość aplikacji – skrócona do zaledwie około 3 minut przed rozpoczęciem eksperymentu oraz 1 minuty czyszczenia przy pomocy 70-procentowego roztworu alkoholu izopropylowego po jego zakończeniu – diametralnie zwiększa przepustowość badawczą laboratoriów, ułatwiając zbieranie potężnych zbiorów big data wymaganych przez obecne modele AI.²

Morfologia Danych Surowych i Cyfrowe Zarządzanie

Impedancją (DSI-Streamer)

Rozumienie architektury fizycznej sprzętu jest nierozdzielnie połączone z analizą wyjściowych formatów cyfrowych. Komunikacja hardware'u z systemami operacyjnymi obsługiwana jest przez dedykowane, darmowe oprogramowanie DSI-Streamer.² Narzędzie to nie tylko służy do nagrywania danych, ale stanowi kompleksowy serwer telemetry, oferując wbudowany monitor impedancji w czasie rzeczywistym, funkcjonalność uśredniania ERP oraz obsługę niestandardowych montażu pomiarowych. Ważnym aspektem jest zdolność DSI-Streamera do transmisji ciągłego strumienia EEG za pośrednictwem gniazd TCP/IP, natywnego API napisanego w języku C oraz protokołu Lab Streaming Layer (LSL), co wprost umożliwia wpięcie systemu w nowoczesne architektury zamkniętej pętli (closed-loop) przetwarzające sygnały z opóźnieniem rzędu pojedynczych milisekund.¹

Standardowymi kontenerami plików dla DSI-24 są powszechnie uznane formaty EDF (European Data Format) oraz CSV (Comma Separated Values).¹⁷ Badanie empirycznego rzutu danych NBackExample_imp.csv, pochodzącego z wielokanałowego zapisu zadania obciążającego pamięć roboczą (N-Back task) z 1 kwietnia 2026 roku, dostarcza rygorystycznego wglądu w sposób strukturyzacji danych cyfrowych urządzenia.²³ Plik ten zawsze rozpoczyna się blokiem metadanych. Zarejestrowane metadane definiują m.in. użyty sprzęt (Headset_Name =,DSI-24), logger danych, systemową weryfikację czasu nagrania, identyfikator badanego podmiotu oraz unikalny rekord sesji (Patient_ID =,X M 01-JAN-0000 X).²³

Poniżej nagłówek metadanych ustrukturyzowana jest macierz główna, której kolumny definiują wektory poszczególnych źródeł sygnału w zsynchronizowanym czasie (wyrażonym w indeksach bądź jednostkach czasu obliczanych na podstawie tików zegara).¹⁹ Bezpośrednia analiza próbek sygnałowych dostarcza krytycznej wiedzy na temat natury surowego zapisu EEG z suchych elektrod. Przykładowo, w pierwszym zaindeksowanym kwancie czasowym wartości rejestrowane na elektrodach, wyrażone po aplikacji predefiniowanych mnożników sprzętowych (najczęściej jako woltyże bazowe), oscylują odpowiednio: dla kanału ciemieniowego P3 wynoszą 0.302, dla elektrody centralnej C3 – 0.163, a dla czołowej F3 zaledwie 0.124.²³ Istotnym zjawiskiem neurofizjologicznym dostrzegalnym w zapisie surowym jest znaczna dominacja energetyczna sygnałów w rejonach potylicznych. Kanał O1 wykazuje potężną amplitudę rzędu 0.410, natomiast O2 wynosi 0.321, podczas gdy symetryczne odpowiedniki z rejonu czołowego (Fp1, Fp2) notują wielkości poniżej 0.100.²³ Taka nierównowaga przestrzenna jest oczekiwanym rezultatem prowadzonych eksperymentów wzrokowych (takich jak paradygmat N-Back), w których angażowana jest kora wzrokowa, potęgująca synchroniczną oscylację sieci asocjacyjnych.

Niezwykle ważną cechą natywnych formatów CSV z DSI-Streamera jest wbudowany mechanizm diagnostyki błędów. Pliki te rozszerzają klasyczny pomiar o parametry kontrolne: Z(M) określający wartość impedancji styku w megaomach (MΩ) dla każdej elektrody w czasie rzeczywistym oraz BL(uV), który monitoruje fluktuacje napięcia stałego linii bazowej (baseline voltage) w mikrowoltach (μV).²⁴ Zgodnie z reżimem technologicznym firmy Wearable Sensing, optymalna wartość docelowa impedancji kontaktowej powinna plasować się poniżej 1 MΩ.²⁴

Próg 5 MΩ stanowi granicę tolerancji, po której przekroczeniu system uznaje połączenie za zerwane na skutek zanieczyszczenia złącza lub kompletnego oderwania elektrody od skóry pacjenta.²⁴ Jeżeli parametry sygnału drastycznie odbiegają od norm bezpieczeństwa (np. przy silnych artefaktach uderzeniowych lub oderwaniu czepka), DSI-Streamer maskuje takie komórki specjalnym identyfikatorem tekstowym Low_SNR.²¹

Analiza próbki badawczej ujawnia mechanizmy tego zjawiska. Po pierwsze, kanały zdefiniowane fabrycznie jako wejścia peryferyjne (X1, X2, X3) notują ciągłe, z nielicznymi fluktuacjami wywołanymi polaryzacją, markery Low_SNR, co świadczy o braku podpiętych dodatkowych urządzeń (np. pasa oddechowego czy elektrod EMG) w danej konfiguracji sprzętowej.²⁰ O wiele istotniejszym problemem dla inżynierii danych są jednak momenty dysrupcji kontaktu na kanałach docelowych. Przykładowo, w indeksie czasowym 56 standardowy zapis ulega przerwaniu na kanale motorycznym C4, gdzie wpisany zostaje status Low_SNR.²³ Jeszcze drastyczniejsza dysrupcja widoczna jest w okolicy indeksu 363, gdzie większość strategicznych kanałów (w tym kora czuciowo-ruchowa i potyliczna) na ułamek sekundy traci wiarygodność pomiarową, a tablica wartości zostaje nadpisana falą sygnatur Low_SNR.²³ Takie anomalie są patologią inherentnie wpisaną w badania w ruchu, wynikającą ze zmian mimiki, ruchów gałek ocznych lub skurczów mięśni karku. Szybki wzrost napięcia bazowego, który ma miejsce podczas nakładania sprzętu lub gwałtownego poruszenia, wymaga nierzadko ręcznego lub automatycznego resetu wartości (funkcja Baseline Reset), aby zapobiec nasyceniu układów cyfrowych.²⁴

Poniższa tabela stanowi zrzut przekroju przez przestrzeń danych czasowych wyizolowanych z pliku NBackExample_imp.csv, ukazując zróżnicowanie aktywności wektorowej oraz losowość występowania dysrupcji.

Czas (Indeks)	Fp1 (Czołowy)	C4 (Centralny)	P3 (Ciemeniowy)	O1 (Potyliczny)	X3 (Aux)	Diagnostyka Zjawiska i Ocena Rejestracji
1	0.092	0.120	0.302	0.410	Low_SNR	Faza początkowa, stabilna integracja; wejścia peryferyjne (X3) rozłączone (impedancja > 5 MΩ). ²³
50	0.095	0.101	0.306	0.412	Low_SNR	Naturalna, stabilna progresja sygnału bez

						fizycznych przemieszczeń układu referencyjnego. ²³
56	0.097	Low_SNR	0.304	0.403	Low_SNR	Krótkotrwałe zerwanie obwodu elektrycznego na elektrodzie C4; interwencja układu diagnostycznego. ²¹
92	Low_SNR	Low_SNR	0.302	0.374	Low_SNR	Złożony artefakt utruty sygnału na obu biegunach skroniowo-czołowych (częsty objaw napięcia czoła). ²³
363	Low_SNR	Low_SNR	0.268	0.393	Low_SNR	Potężny defekt przestrzenny (Low_SNR obejmuje C3, F3, Fz, F4, C4, Fp1); prawdopodobne przesunięcie czepka. ²³

Zarządzanie wektorami z tak nieregularną topologią brakujących danych warunkuje finalny sukces ekstrakcji wiedzy z sygnału. Nowoczesne analizatory szeregów czasowych, takie jak konwolucyjne sieci neuronowe (CNN), transformatory przestrzenno-czasowe, czy modele

Markowa, wymagają rygorystycznie kompletnych macierzy na warstwie wejściowej. Konieczność ta rodzi pilną potrzebę wdrożenia specjalistycznych potoków programowych odpowiedzialnych za bezbłędną interpolację pustych komórek jeszcze na etapie transformacji strukturalnej.

Strategie Przetwarzania Wstępnego i Interpolacji Przestrzennej Sygnałów

Zanim strumień danych EEG zasili układy sztucznej inteligencji, musi poddać się bezwzględnyemu regułom przetwarzania wstępnego (preprocessing). Literatura naukowa potwierdza, że rodzaj, a nawet kolejność wdrażanych kroków preprocessingowych determinuje jakość późniejszej, międzyobiektowej i wewnątrzobiektowej klasyfikacji nierzadko w większym stopniu niż sama architektura modelu klasyfikacyjnego.²⁶ Stwierdzono na przykład, że algorytmy detrendyzacji w dziedzinie czasu oraz specyficzna parametryzacja częstotliwości filtracji (szczególnie cięcia filtrów dolno- i górnoprzepustowych) w sposób krytyczny modyfikują dokładność predykcji. Rygorystyczna analiza wykazała, że choć całkowite ignorowanie złożonych artefaktów (czyli pozwolenie na przedostanie się do sieci strukturalnej szumu fizjologicznego) mogło pozornie podnosić syntetyczną skuteczność dekodowania, działało się to za sprawą wyuczenia się przez sieć szkodliwych korelacji (np. skurczów mięśni zamiast aktywności korowej), niszcząc całkowicie zasadność interpretacyjną modelu.¹³

Dlatego też profesjonalne repozytoria open-source, takie jak Pythonowska biblioteka MNE-Python czy środowisko EEGLAB, ugruntowały swój status standardu branżowego.²⁶ Systemy Wearable Sensing posiadają dedykowane rozszerzenia integracyjne. W starszych kompilacjach stosowano EEGLAB extension v.1.13, jednakże ze względu na poprawki w formacie danych, kompilacje plików DSI-Streamera w wersji od 1.08.90 w górę wymagają zoptymalizowanego modułu EEGLAB Wearable Sensing Extension v.1.14.²⁷ Oprogramowanie to gwarantuje bezstratne wczytywanie danych z poprawną interpretacją jednostkową oraz przestrzeniami lokalizacyjnymi kanałów, stanowiąc kluczowy moduł w analizie wolnych potencjałów i badaniach nad dynamiką snu.¹⁰

Rozwiązaniem problemu nieregularnych i losowych utrat kontaktu – logowanych przez oprogramowanie urządzenia DSI-24 jako markery Low_SNR – jest wykorzystanie zaawansowanych systemów interpolacji przestrzennej.²⁸ Funkcja `mne.interpolate_bads` z biblioteki MNE-Python to absolutny fundament walki z utratą rzetelności wielokanałowego rejestru.³⁰ Podczas gdy dla systemów magnetoencefalograficznych (MEG) wykorzystywane są złożone metody oparte na mapowaniu pola z użyciem rozwiązania propagacji w przód (forward solution field mapping), w obszarze standardowego zapisu EEG oprogramowanie wykorzystuje model sferycznych splajnów (spherical splines interpolation).²⁸ W obiekcie `raw` struktura listująca wadliwe elektrody znajduje się w atrybucie `raw.info['bads']`.

Aparat matematyczny funkcji `interpolate_bads` operuje na założeniu rzutu topograficznego mózgowca na trójwymiarową sferę jednostkową.²⁹ Niech N oznacza liczbę w pełni sprawnych elektrod na sferze czaszki (tych z niską impedancją, wolnych od szumów). Dla

każdej sprawnej elektrody znamy jej euklidesowy wektor położenia na sferze, $\mathbf{r}_i$, i możemy w sposób wiarygodny przyporządkować jej aktualną wartość zarejestrowanego potencjału czasowego $V(\mathbf{r}_i)$. Kiedy system napotyka usterkę sygnałową na elektrodzie usytuowanej w pozycji $\mathbf{r}$ (np. awaria sensora C4 przy indeksie 56), wartość potencjału $\hat{V}(\mathbf{r})$ ulega aproksymacji na podstawie otaczającej go chmury zdrowych odczytów, poprzez konstrukcję odpowiednio sformułowanej i ciągłej na sferze funkcji bazowej:

$$V(\mathbf{r}) = c_0 + \sum_{i=1}^N c_i g(\cos(\mathbf{r}, \mathbf{r}_i))$$

Funkcja $g(x)$, która modeluje spadek korelacji sygnału wzdłuż łuku sferycznego między dwiema pozycjami, zdefiniowana jest matematycznie z wykorzystaniem nieskończonego szeregu opartego na wielomianach Legendre'a $P_n(x)$:

$$g(x) = \frac{1}{4\pi} \sum_{n=1}^{\infty} \frac{2n+1}{n^m(n+1)^m} P_n(x)$$

Równanie to zakłada konieczność obliczenia współczynników interpolacji wektora

$\mathbf{c} = [c_1, c_2, \dots, c_N]^T$ oraz współczynnika stałego c_0 , rozwiązując precyzyjnie sformułowany układ równań macierzowych narzucający rygor minimalizacji energii krzywizny z

dodatkowym ograniczeniem algebraicznym $\sum_{i=1}^N c_i = 0$. W kodzie implementacyjnym Pythona kluczową kwestią jest wywołanie metody z odpowiednią flagą bezpieczeństwa (np. `reset_bads=False`), dzięki czemu uszkodzone kanały zostają wprawdzie odbudowane na podstawie danych z sąsiedztwa i stają się użyteczne do analiz matematycznych, ale jednocześnie zachowują etykietę informującą naukowców o ich rekonstruowanym pochodzeniu, powstrzymując proces degradacji wiedzy o pierwotnej autentyczności sygnału.²⁸ Dodatkowo MNE wymusza zabezpieczenia systemowe w postaci weryfikacji pozycji elektrod, podnosząc wyjątki bezpieczeństwa `on_bad_position="warn"`, gdy do biblioteki zostaną przesłane naniesione sztucznie uszkodzone mapy topologiczne.³¹ Metoda ta bywa czasami w dyskusjach open-source konfrontowana z alternatywnymi systemami dla pokrewnych modalności (np. fNIRS), gdzie trwają dyskusje nad stosowaniem odległości Euklidesowej do maskowania średnią (Nearest Neighbor) zamiast transformacji sferycznej.³²

Rozwiązanie oparte o splajny sferyczne zachowuje globalne zależności i korelację fazową w obrębie topologii czepka, co jest konieczne dla sieci oceniających zjawiska takie jak koherencja przestrzenna sygnału we wczesnych objawach epilepsji.⁵ Jeśli awarii ulega większość elektrod nagle (np. indeks 363 w pliku DSI-24), matematyka sferyczna staje się bezużyteczna wskutek drastycznego braku węzłów referencyjnych.²³ Tam, gdzie standardowe procesy inżynierii wejściowej zawodzą w ustandaryzowaniu losowej geometrii wariancji międzypersonicznej, do głosu dochodzi konieczność całkowitego porzucenia ciągłych modeli fal

mózgowych na rzecz potężnych autoenkoderów i wektorowej kompresji dyskretnej.

Teoretyczne Podstawy Dyskretyzacji Sygnałów: Od VAE do VQ-VAE

Głębsza ewolucja narzędzi analitycznych w neuroinformatyce przeniosła środek ciężkości ze zwykłych sieci konwolucyjnych wprost do domen generatywnych.³⁴ Najistotniejszą przeszkodą w budowie zgeneralizowanych klasyfikatorów dla sygnałów bioelektrycznych był deficyt ustrukturyzowanych zbiorów uczących dla konkretnych stanów (tzw. problem data scarcity).³⁵ Początkowe próby zastosowania wariacyjnych autoenkoderów (VAE – Variational Autoencoders) do redukcji wymiarowości i generowania prób EEG odniosły mieszany sukces.⁵ Architektura VAE, w swojej kanonicznej formie, wykorzystuje dwie współzależne struktury: enkoder i dekoder. Enkoder mapuje zawiły, wielokanałowy sygnał EEG o dużym rozmiarze

wymiarowym na ciągłą reprezentację ukrytą $\mathbf{z}$ w przestrzeni latentnej. W ujęciu stochastycznym, w przeciwieństwie do standardowych autoenkoderów, VAE nie określa sztywnego wektora punktowego, ale szacuje dwa parametry definicyjne dla każdego sygnału wejściowego: wektor wartości średniej (mean) i wektor wariancji (variance) (w implementacjach numerycznych najczęściej w postaci logarytmu, dla zabezpieczenia ciągłości funkcji optymalizacyjnej).³⁵ Przebieg tej koncepcji sprawia, że dekoder otrzymuje próbki wygenerowane bezpośrednio z owego narzuconego wielowymiarowego rozkładu Gaussa, ucząc się rekonstruowania sygnału o nieliniowych relacjach, charakteryzujących wpływ autonomicznych procesów (np. oddechu czy bicia serca) na hemodynamiczną oscylację kory.³⁵ Modele VAE udowodniły swoją wartość w zadaniach diagnozowania padaczki, klasyfikacji etapów snu czy obrazowania zmian rozwojowych u pacjentów pediatrycznych, gdyż wykstrahowana w nich uogólniona zmienna utajona zawiera potężne skondensowane cechy strukturalne mózgu.⁵

Niemniej jednak, operowanie w ciągłej przestrzeni probabilistycznej uwydatniło fundamentalne słabości VAE, w tym destrukcyjne zjawisko kolapsu rozkładu a-posteriori (posterior collapse). W takich warunkach zaawansowane autogresywne dekodery z czasem zaczynają ignorować sygnał płynący z enkodera ukrytego, faworyzując własną dystrybucję w budowie struktury danych wyjściowych.³⁵ W neuroinformatyce, gdzie relacje między amplitudami i mocami pasm poszczególnych elektrod stanowią kruchą, niestacjonarną tkankę, takie "rozmycie" wiedzy jest kategorycznie niedopuszczalne.

Rewolucją, zapożyczoną bezpośrednio ze spektakularnych sukcesów dziedzin generowania obrazu i dźwięku, było zaadaptowanie w EEG struktury znanej jako VQ-VAE (Vector Quantized Variational Autoencoder).⁸ Całkowicie porzuca ona rygor generowania ciągłej przestrzeni opartej o wariancję. VQ-VAE polega na bezkompromisowym rzutowaniu ciągłych wektorów informacji (najczęściej ustrukturyzowanych z cech topograficznych i transformat czasowo-częstotliwościowych) prosto w sztywne, dyskretne warianty przestrzenne znane pod nazwą słownika kodowego (codebook embeddings).⁸

Paradygmat działania wektorowej kwantyzacji układa się w trójetapowy potok:

1. **Ekstrakcja Ciągła:** Moduł enkodera sieci przetwarza łaty (patches) surowego sygnału EEG i produkuje serię wektorów ciągłych $\mathbf{Z}_e$ w zredukowanej objętości przestrzennej.
2. **Kwantyzacja i Hard Selection:** Sieć porównuje wektor $\mathbf{Z}_e$ ze wszystkimi atomowymi reprezentacjami $\mathbf{e}_j$ stacjonującymi w ogromnej macierzy wyuczonego słownika $\mathbf{C} = \{\mathbf{e}_1, \dots, \mathbf{e}_K\}$ (tzw. codebook). System narzuca bezkompromisowe poszukiwanie i przyporządkowanie (najczęściej oparte na wyliczaniu cosinusa odległości lub normy euklidesowej). Ciągły wektor sygnału zostaje bezpowrotnie zastąpiony najbliższym sąsiadującym atomem:

$$\mathbf{Z}_q = \mathbf{e}_k, \quad \text{gdzie} \quad k = \operatorname{argmin}_j \|\mathbf{Z}_e - \mathbf{e}_j\|_2$$

To na tym etapie zachodzi proces o drastycznym wpływie na model: stochastyczność oporności kontaktowych (zjawiska Low_SNR), fluktuacje bioelektryczne niezwiązane z zadaniem testowym oraz zakłócenia miograficzne są w mgnieniu oka "odcinane", a sygnał zostaje siłowo ustandaryzowany do konkretnego, wysoce zoptymalizowanego "słowa" ze słownika.⁹

3. **Dekodowanie:** Moduł transformujący otrzymuje w sekwencji wyłącznie dyskretne tokeny $\mathbf{Z}_q$, z których jest w stanie autogresywnie odbudować widmo sygnału.

Zarządzanie twardą dyskretyzacją funkcji argmin, która niszczy możliwość przeprowadzania standardowej propagacji wstecznej gradientu (backpropagation) z powodu swojej nieróżniczkowalności, wymaga inżynierskiego podejścia estymatora przepływu bezpośredniego (Straight-Through Estimator). Optymalizacja tej kłopotliwej struktury jest zaszyta w specjalnie wyliczanej wieloczołowej funkcji błędu:

$$\mathcal{L} = \underbrace{\|\mathbf{X} - \hat{\mathbf{X}}\|_2^2}_{\text{Błąd Rekonstrukcji}} + \underbrace{\|\operatorname{sg}[\mathbf{Z}_e] - \mathbf{e}_k\|_2^2}_{\text{Aktualizacja Słownika}} + \underbrace{\beta \|\mathbf{Z}_e - \operatorname{sg}[\mathbf{e}_k]\|_2^2}_{\text{Commitment Loss}}$$

Użycie operatora zatrzymania gradientu, oznaczonego jako $\operatorname{sg}[\cdot]$ (stop-gradient), gwarantuje stabilność układu. Błąd rekonstrukcji narzuca jakość odbudowanego sygnału $\hat{\mathbf{X}}$. Drugi element zmusza przestrzeń słownika kodowego do podążania za rzeczywistym dystrybuantem ciągłym enkodera. Ostatni czynnik, skalowany hiperparametrem β , działa stymulująco w odwrotną stronę – komituje enkoder do ograniczenia swojego rozrzutu, wiążąc go niejako grawitacyjnie z bliskimi osadzeniami słownika, co przeciwdziała nagłym rozwarstwieniom modelu optymalizacyjnego. Skwantyzowana reprezentacja służy następnie za dyskretny, odporny interfejs wyizolowany z fizjologicznej matrycy, stając się idealnym klockiem konstrukcyjnym dla modeli asystujących.

Dekompozycja Superpozycji: Model AtomVQVAE i Rzadkie Kodowanie

Architektura twardej selekcji z klasycznego modelu VQ-VAE, pomimo swoich fundamentalnych zalet adaptacyjnych, nie we wszystkich warunkach odzwierciedla naturę zjawisk biologicznych. Rzutowanie całego płata sygnału wyłącznie na jedną stałą komórkę ukrytą z macierzy kodowej (czyli wytwarzanie w pełni rzadkiego wektora dystrybucji z tylko jedną niezerową wartością, tzw. one-hot vector) ¹⁴ świetnie sprawdza się w lingwistyce bądź grafice dwuwymiarowej. Jednakże w przypadku elektroencefalografii, każdy potencjał zmierzony na powierzchni skalpu przez 24-kanalowy zestaw DSI-24 jest zawsze wynikiem sumacji i interferencji niezliczonych prądów zewnątrzkomórkowych dipoli elektrycznych zagnieżdżonych w rozmaitych strukturach kolumnowych kory mózgowej, co stwarza skrajny przypadek problemu nakładania źródeł (superposition problem). Ograniczenie reprezentacji do jednego, twardego dobrego wektora bywa rażącym, bezstratnym niedoszacowaniem, prowadzącym do nieuzasadnionego ucięcia danych (underfitting) o strukturze nakładającej się na tło. ¹⁴

Na kanwie tego krytycznego dylematu narodziła się uogólniona wariacja sieci znana jako **AtomVQVAE**. ¹⁴ Została ona zdefiniowana jako architektura modyfikująca węzeł wąskiego gardła ukrytego z pojedynczego przydziału rygorystycznego w kierunku tzw. selekcji elastycznej lub miękkiej. Odbywa się to poprzez fuzję metodyki VQ-VAE z paradygmatami z dziedziny rzadkiego kodowania (Sparse Coding) oraz zaawansowanymi mechanizmami wyuczania słowników uwarunkowanych zadaniowo (Task-Driven Dictionary Learning). ¹⁴

Zasada leżąca u podstaw AtomVQVAE nakazuje, by surowa, skompresowana warstwa ciągła sygnału wytworzona przez moduł enkodera nie decydowała się wyłącznie na jeden jedyny,

"zwycięski" wektor słownika. Wektor z dyskretnej przestrzeni latentnej $\mathbf{Z}_q$ jest konstruowany poprzez optymalną kombinację liniową stosunkowo małego, celowo dobrego ułamka

wszystkich atomowych komponentów dostępnych w przestrzeni kodowej $\mathbf{D}$:

$$\mathbf{Z}_q = \mathbf{D}\alpha$$

Warunkiem koniecznym tej transformacji jest dbanie o to, aby macierz wag w rzadkiej strukturze

kombinacyjnej, określana jako α , nie zapełniła się wielkościami ciągłymi, ale zachowała rygor optymalizacji rzadkiej (gdzie znaczna część współczynników wagowych wymuszana jest jako absolutne zero). ¹⁴ Mechanizm ten pozwala rozplątać zbiegające się z różnych ośrodków fale z zachowaniem dyskretności cech modelowych.

Realizacja tych nieliniowych postulatów w ekosystemach w pełni różniczkowalnych (z włączonym mechanizmem auto-differentiable dla biblioteki PyTorch) stwarza wyjątkowe wyzwanie programistyczne, któremu repozytoria opublikowane w otwartym dostępie (na czele z projektami takimi jak AtomVQVAE ¹⁴) potrafiły z sukcesem sprostać. Rdzeń ich optymalizacji stanowi adaptacja potężnych szybkich iteracyjnych algorytmów. Programiści zaimplementowali na poziomie procesora graficznego rozproszone architektury solverów OMP (Orthogonal Matching Pursuit), charakteryzujące się metodologią zachłanną polegającą na wyłapywaniu atomów najlepiej zmniejszających próg błędu resztkowego oraz, będącego standardem branżowym, algorytmu FISTA (Fast Iterative Shrinkage-Thresholding Algorithm). ¹⁴ FISTA reprezentuje metodykę optymalizacyjną bazującą na spadku wielomianowym proksymalnych

gradientów z włączoną regułą rzutowania dla operatora miękkiego progowania, celując w karanie parametru wektora zgodnie z normą $\mathcal{L}_1$.¹⁴

Element Składowy	Kanoniczny VQ-VAE	Rzadki System AtomVQVAE
Koncepcja Przydziału	Ekstrakcja jednego najbliższego wektora z macierzy (1-NN)	Wyliczenie małego podzbioru wspierającego, jako kombinacja rzadka. ¹⁴
Wynik Operacji Latentnej	Wektor o charakterze twardym z pojedynczym znacznikiem	Konstrukt zawierający macierz aktywacji wielu atomów równoległe. ¹⁴
Procesy Minimalizujące	Równania oparte o proste minimalizowanie luki cosinus/Euklides	Różniczkowalne wdrożenie iteracyjnych algorytmów optymalizacyjnych FISTA oraz OMP. ¹⁴
Korelacja z Naturą EEG	Ryzyko utraty nałożonych oscylacji w paśmie wielowymiarowym	Wierne odwzorowanie dyfuzyjnej natury sygnałów pochodzących ze źródeł zlokalizowanych. ¹⁴

Dzięki oparciu wektorowych przestrzeni dyskretnych na strukturach pozwalających zachować równowagę pomiędzy absolutną sterylizacją z szumów, a niezbędnym zachowaniem głębi w superpozycji danych, generowanie słowników stało się potężnym akceleratorem budowy uogólnionych architektur bazowych.

Fundacyjne Modele EEG i Zjawisko Maskowanej Predykcji Tokenów (MTP)

Sukces koncepcji VQ-VAE udowodnił, że wyekstrahowana przez niego przestrzeń ukryta stwarza środowisko wolne od modalnych i technicznych barier zakłócających zbieżność treningową. Spostrzeżenie to było bezpośrednim katalizatorem wyodrębnienia nowej dziedziny w neuroinformatyce: Modeli Fundacyjnych EEG (EEG Foundation Models – EFM_s).⁷

Różnorodność konfiguracyjna, gdzie jedna klinika operuje 24-kanalowym systemem DSI, inna używa potężnego układu 128-kanalowego, a powszechne interfejsy konsumenckie korzystają z urządzeń 2-kanalowych, do tej pory wymuszała mozolne transferowanie wag i nieprzystosowanie parametrów wejściowych modeli lokalnych.⁷

Modele fundacyjne, bezpośrednio podążając ścieżką zdefiniowaną w modelach językowych (NLP) za pomocą transformatorów BERT i struktur Masked Language Modeling, przyjmują w EEG podejście zwane uczeniem reprezentacji w ujęciu łatanym (patch-wise representation learning).⁷ Podejście to dzieli zsynchronizowany przepływ danych ze wszystkich elektrod na relatywnie małe, spójne kafelki (patches), izolujące charakterystyki częstotliwościowe i wymiary w czasie. Na tych zhomogenizowanych oknach uruchamia się pre-trenowany dekodery architektury opartej na VQ-VAE (nazywany w tym przypadku "Tokenizerem" sygnału), który bez

skrupułów transformuje wszystkie łaty na listę ciągłych indeksów ukrytych leżących bezpiecznie w jego dyskretnej książce kodowej (codebook).⁹

Skwantyzowane tokeny poddawane są najskuteczniejszej formie głębokiego, zgeneralizowanego uczenia samonadzorowanego (Self-Supervised Learning) za pośrednictwem architektury określanej jako MTP (Masked Token Predictor).⁹ System wymusza wstrzyknięcie uczonego parametru maskującego (learnable mask) w miejsce losowo wybranych fragmentów oryginalnego, w pełni przesyłanego ciągu wejściowego.⁹ Okaleczony w ten sposób strumień danych trafia do wielowarstwowej sieci transformatorów wyposażonych w koder położeniowy z domieszką sinusoidalną oraz zintegrowanymi relacjami kanałowymi.⁹ Celem zadania głębokiego rozróżniania ukrytego nie jest bezpośrednia rekonstrukcja surowych wartości mikrowoltów czy spektrogramu gęstości widmowej.⁹ Od sieci wymaga się skomplikowanego, analitycznego dedukowania – zgadnięcia, który z dyskretnych indeksów wyuczonych przed chwilą przez Tokenizer VQ-VAE stanowi prawidłową, spójną kontynuację wymazanego kafelka. Sieć operuje wtedy wyłącznie w znormalizowanej metryce kosinusowej, całkowicie uodparniając się na jednostkowe kaprysy sygnału referencyjnego czy szumy aparaturowe.⁹

Paradygmat ten reprezentują obecnie potężne struktury analityczne opublikowane w otwartych repozytoriach naukowych. LaBraM (Large Brain Model) wyznaczył trendy stosując uniwersalną predykcję tokenów z koderem i dekerem dyskretnym, tworząc wektorowy silnik uczenia generycznych reprezentacji dla niespotykanej wcześniej skalowalności do nawet 128 kanałów na zrestrukturyzowanym mechanizmie warstw wejściowych pozycjonowania (EAD adapter).⁴⁰

Koncepcja ta doprowadziła do dalszej segmentacji innowacji: platforma EEGPT wyspecjalizowała się w wydajnym maskowaniu z użyciem samo-nadzoru wielotorowego opierając swą logikę na podziale widmowym, podczas gdy architektura CBraMod skierowała zdolności decyzyjne ku potężnym technikom uwagi typu "criss-cross" (criss-cross attention), separującym analizę zależności sprzężeń czasowych od skorelowanych połączeń przestrzennych międzypółkulowych.³⁴ Po wstępnej rozgrzewce z zamaskowanymi tokenami, ten sam bazowy model (Base Foundation Model) wymaga zaledwie płytkiego procesu dostrajania (fine-tuning) na skrajnie ograniczonym zestawie etykietowanych danych pacjenta by osiągać wiodące wyniki we wdrożeniach klasyfikacji klinicznej.

Skalowalne Środowisko Generatywne i Integracja Translacyjna z LLM (EEG-to-Text)

Osiągnięcie zdolności transformacji szumów biologicznych, zbieranych przez urządzenia klasy DSI-24, w strumień przewidywalnych, generycznych i matematycznie uporządkowanych reprezentacji stanowiło bramę do zdefiniowania elektroencefalografii jako pełnoprawnej dziedziny inżynierii wejść do dużych sieci wielomodalnych. Jeśli architektury VQ-VAE potrafią sformułować słownik dyskretnych, strukturalnych osadzeń ukrytych charakteryzujących stan obciążenia kognitywnego lub wzorca intencji motorycznej (tzw. codex embeddings), omija się całkowicie złożony problem korelacji i różnic w ciągłej geometrii danych od indywidualnych cech pacjenta.¹¹ Wektory te, z perspektywy wejścia komputerowego, przestały być odczytem

woltościomierza; stały się sekwencją spójnych tokenów, będących syntaktycznie równoznacznymi z embeddingiem tekstowym czy pikselem tokenizowanego obrazu. To spostrzeżenie zaowocowało błyskawicznym wdrożeniem paradygmatów wyrównywania i harmonizacji strumieni biologicznych do strumieni semantycznych z natywnych modeli językowych (Large Language Models – LLM).¹¹ Metodologie harmonizacji klasyfikuje się dwutorowo. Pierwszym jest wymuszenie korespondencji przez specyficzne rygorystyczne funkcje startowe.¹² Algorytm taki jak MTAM poszukuje symetryczności pomiędzy ciągłymi elementami układów ukrytych sieci mózgu, a wielowymiarowymi sferami lingwistycznymi opisującymi bodziec docelowy przy użyciu złożonych aparatów analizy korelacji kanonicznych (Canonical Correlation Analysis) oraz aproksymowania Dystansu Wassersteina (Wasserstein Distance).¹² To drugie ujęcie architektoniczne jest jednak znacznie bardziej obiecujące. Podejście polegające bezpośrednio na wprowadzeniu tokenizowanych osadzeń ukrytych z koderów sygnałów korowych do warstwy wejściowej szerokich platform dekodekacji z modeli NLP takich jak BART, sieci T5 (Text-to-Text Transfer Transformer), LLaMA, czy mniejszych wariantów klasy MiniLM.¹¹

Techniki te doprowadziły do eksplozji zadziwiających zastosowań cross-modalnych. Architektury eksperymentalne zaprzęgnięto m.in. do bezpośredniego dekodowania fali mózgowych wzbudzonych odsłuchiowaniem sygnałów i mapowania ich prosto do transkrybowanego tekstu przy absolutnym pominięciu generowania etapu mowy czy ręcznej transkrypcji (end-to-end text decoding) za pomocą pre-trenowanego modelu Whisper od firmy OpenAI.¹³ Włączenie fazowej dyskretyzacji i skompresowania kodu do semantycznie oczyszczonego słownika odegrało rolę zapory, unikając wyuczenia korelacji urojonych na przesunięciach wektorowych czy fałszywych artefaktach fali mięśniowej.¹³

W zastosowaniach klasyfikacyjnych korzyści z tej drogi przekładają się wprost na potężne wskaźniki bezbłędnej oceny. Implementacja wielowarstwowej rury decyzyjnej z pomostem na reprezentacje językowe owocuje przełomową poprawą celności detekcji (np. zjawiska Zero-shot w zmysłowej predykcji nastroju, gdzie bezpośrednia detekcja EEG oferowała wskaźnik F1 w okolicach 37.1%, zaś z implementacją pośrednią warstw lingwistycznych wystrzeliła do absurdalnych 68.18%).¹¹ W literaturze klinicznej odnajdujemy twarde dowody skuteczności rzadkich reprezentacji w detekcji patologii wczesnych faz rozwoju padaczki (z minimalizacją średniego czasu ewaluacji segmentu od 26ms na preprocessing do 1.57ms dla oceny zaawansowanego sieciowego modelu szumu dla systemu zdykretyzowanego pod DDPM).⁵ VQ-VAE służy ponadto do dekodowania potężnej nieliniowości między fizjologią a dynamiką krążenia kory z wielowymiarowego rejestru fMRI w poszukiwaniu ukrytej siatki fluktuacji oddechowych.³⁷ Działanie modelu potwierdzono w zbiorze EESM-23, w którym wdrożone po głębokim treningu wektory służyły do wydajnej ewaluacji wzorców i precyzyjnej oceny specyfiki zmian u pediatrycznych stadiów rozwojowych i predykcji oscylacji snu.⁵

Na podobnych mechanizmach zbudowane zostały modele SAnoDDPM czy pokrewne hybrydowe dyfuzje (Diffusion models) i generatywne sieci kontradiktoryjne (GANs) w celu zlikwidowania bariery małych woluminów eksperymentów poprzez wygenerowanie z puli tokenów nieskończonych serii spójnego, fizjologicznie wiarygodnego szumu naśladującego zapis referencyjnego zestawu (EEG data augmentation).³⁴

Demokratyzacja Infrastruktury i Inkluzja Skryptowa Modelu Open-Source

Ogromna złożoność mechanizmów ukrytych, oparta na predykcji rzadkich kombinacji sferycznych oraz fine-tuningu wielomiliardowych modeli transformatorowych, staje w wyraźnej sprzeczności z wygórowanymi progami wejścia w inżynierię technologiczną. Badania i weryfikacja algorytmów realizowanych na sprzęcie wartości dziesiątek tysięcy dolarów – m.in. wspomnianym DSI-24 czy DSI-7 – narzuca drastyczny elitaryzm. Odpowiedzią na tę sytuację i kołem napędowym wdrożeń aplikacyjnych są otwarte i interaktywne portfolia zrzeszonej wokół globalnych repozytoriów społeczności developerskiej open-source, adaptujące potężne technologie dla urzędów ogólnodostępnych.

Skalowanie złożonych potoków uczenia w dół, na poziom systemów budżetowych, znakomicie reprezentują zróżnicowane przedsięwzięcia obecne na powszechnych forach udostępniających oprogramowanie typu open-source, co doskonale widać na przykładzie inicjatyw skupionych pod parasolem kontrybutorów (np. portfolia Wojtekb30). Obejmują one repozytoria tworzące innowacyjne obudowy programowe dążące do obejścia komercyjnych restrykcji, jak na przykład pyDirectMindwave.⁴⁷ Stanowi ona wysiłek skonstruowania niezależnej, darmowej paczki klas w języku Python ułatwiającej odczyty strumieniowe i logikę surowych przebiegów z konsumenckich urządzeń neurosprzężenia zwrotnego (np. NeuroSky Mindwave Mobile 2) przy użyciu standardowego połączenia Bluetooth, z całkowitym włączeniem w obieg skryptowy pozbawiony zewnętrznych bramek autoryzacyjnych lub porzuconych modułów oficjalnych (ThinkGear Connector).⁴⁷

Użyteczność bezpośrednich skryptów streamingowych z popularnych sensorów do rdzenia w programie Python umożliwia zaimplementowanie na niższym szczeblu opisywanych we wcześniejszych segmentach rozproszonych architektur wektorowych (takich jak kody iteracyjne AtomVQVAE) za ułamek ceny, tworząc potężny inkubator innowacji analitycznych w czasie rzeczywistym. Repozytoria te wpisują się w spójną architekturę oprogramowania, która testowana bywa rzetelnie na wielorakich płaszczyznach – kompresji obiektów multimedialnych na warstwach (jak pakiety ograniczników rozmiaru VideoCompressor), tworzenia integracji zewnętrznych kanałów z tanimi systemami podsystemów uwarunkowanych (mikrokontroler zintegrowany z API w obrębie Discord-Bot-Pi-Pico-Display) oraz mechanizmów oszczędzających pamięci (Clipboard-saver).⁴⁹

Co więcej, ekosystem open-source bierze wprost na swoje barki wysiłek budowy zindywidualizowanych narzędzi asystujących w dostosowaniu wspomnianych wcześniej dużych modeli LLaMA czy T5 do funkcji dekodujących wielomodalnych dla sygnałów wektorowych. Doskonałym przejawem udoskonalania mechaniki integracji domenowej i dostrajania (Instruction fine-tuning) pod polskojęzyczne i specyficzne semantycznie aplikacje asystujące (LLaVA - Large Language-and-Vision Assistant) jest generacja uwarunkowanych instrukcyjnych zbiorów danych, jak pakiet llava-1.5-665k-instructions-Polish bazujący na masowej destylacji tłumaczenia poprzez implementację sieci NLLB-200 (facebook/nllb-200-distilled-600M) bez zapędów komercyjnych, na licencji Creative Commons Attribution Non Commercial 4.0.¹⁵

Wyniki adaptacji tego wielkiego woluminu tekstowo-wizyjnego zasilają precyzyjne dotrenowywane modułowo, hybrydowe pakiety takie jak modele instrukcyjne z gałęzi Bielik-1.5B-v3.0-VLM-Instruct czy skwantyzowane w formacie GGUF bloki wnioskujące Bielik-4.5B-v3.0-Instruct-Q6_K-GGUF.¹⁵ Model z rodziny Bielik udowadnia, że nawet modele z silnie zredukowaną ilością bitów, dedykowane na mniejsze farmy serwerowe czy stacje brzegowe (Edge AI), posiadają rewelacyjny wskaźnik przyswajania korelacji pomiędzy wektorami tokenizowanymi z dowolnej macierzy ułożonych dyskretnie stanów wielomodalnych. Ta pełna elastyczność i skalowalność techniczna narzędzi językowych od poziomu abstrakcyjnych algorytmów dekodowania VQ-VAE, aż po implementacje na stacjach konsumenckich połączonych ze zwinnymi systemami typu Mindwave, ustanawia spójny schemat, w którym modele generatywne nie stają się produktem niszowym, a zgeneralizowaną podbudową dla interakcji człowieka ze środowiskiem obliczeniowym.

Zakończenie

Ewolucja interfejsów służących do analizy aktywności fal korowych mózgu napędzana jest obecnie przez rezygnację z przestarzałych paradygmatów badawczych na rzecz zsynchronizowanych technologii sprzętowych i rewolucyjnych algorytmów ukrytej przestrzeni. Profesjonalny sprzęt z rodziny Wearable Sensing DSI-24 stanowi wierzchołek optymalizacji telemetrii fizjologicznej – wprowadzając bezprecedensowy parametr $47\text{ G}\Omega$ impedancji wejściowej i zjawiskowy wskaźnik tłumienia 120 dB, aby na zawsze wyeliminować potrzebę sterylnych laboratoriów, otwierając elektroencefalografię na testowanie dynamiki w otoczeniu środowiska pacjenta, generując w ten sposób gigantyczne, niezmaczone bloki surowych plików telemetrii w trybie rzeczywistym.

Konsekwencją zbierania danych w skrajnych pozycjach obciążeń – co bezpośrednio weryfikuje stochastyczne zagęszczenie awaryjnych rejestrów odciętej korelacyjności definiowanych sprzętowo markerami zapadowymi na standardowym zrzuć danych w postaci tablic – jest narzucenie absolutnej precyzji w algorytmach odsumiających i odbudowie utraconych map geometrycznych przez programowe interfejsy sferycznych splajnów za pośrednictwem bibliotek wektorowych. Przekroczenie klasycznego ograniczenia w generowaniu wyrafinowanych systemów klasyfikujących odbywa się na drodze dyskretyzacji strukturalnej. Architektura wektorowych wariacyjnych autoenkoderów (VQ-VAE) ratuje dane biofizjologiczne przed zapadaniem ukrytym, a implementacje wyuczonego słownika opierające selekcję dyskretną na złożonych strukturach szybkiego rzadkiego kodowania (jak innowacje w paradygmacie AtomVQVAE optymalizującym za pomocą spadków FISTA z regularyzacją) rozkładają potężne fuzje dipoli na ujednolicone klocki semantyczne.

Transformacja ta owocuje zdefiniowaniem bezbłędnej warstwy uniwersalnych generatorów ujętych w ramy Modeli Fundacyjnych, wyposażonych w zdolności maskowanej predykcji tokenowej, przenikając w ten sposób barierę domeny czysto medycznej i bezpośrednio łącząc fale biologiczne z nieskończonymi zasobami i zdolnościami kognitywnymi dużych wektorowych modeli językowych. Poprzez masowe inicjatywy środowisk developerskich, od niskopoziomowych wtyczek strumieniujących w czystym języku skryptowym do zaawansowanych translacji instrukcji uwarunkowanych (takich jak ekosystem wielomodalnych

platform pokroju modelu Bielik i potoków danych w formacie LLaVA z zachowaniem skomplikowanych zawłości i lokalnych kontekstów językowych), wizja integracji sprzężenia bezpośredniej wymiany świadomych intencji fizjologicznych na strumień cyfrowy przestaje być wyłącznie koncepcją referencyjnych stacji klinicznych, a ewoluuje w uniwersalny i ogólnodostępny pomost o gigantycznych reperkusjach analitycznych.

Cytowane prace

1. DSI-24 (Wearable Sensing) | NEUROSPEC, otwierano: maja 18, 2026, <https://www.neurospec.com/products/dsi-24>
2. DSI-24 - Wearable Sensing | Dry EEG, otwierano: maja 18, 2026, <https://wearablesensing.com/dsi-24/>
3. DSI-24 | Wearable Sensing, otwierano: maja 18, 2026, https://wearablesensing.com/wp-content/uploads/2021/12/Wearable-Sensing-DSI-24-Specification-Sheet_s.pdf
4. Effects of Changes to Architectural Elements on Human Relaxation-Arousal Responses: Based on VR and EEG - PMC, otwierano: maja 18, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC8074029/>
5. VAEED: Variational auto-encoder for extracting EEG representation - PubMed, otwierano: maja 18, 2026, <https://pubmed.ncbi.nlm.nih.gov/39571641/>
6. [2312.09449] vEEGNet: learning latent representations to reconstruct EEG raw data via variational autoencoders - arXiv, otwierano: maja 18, 2026, <https://arxiv.org/abs/2312.09449>
7. CodeBrain: Bridging Decoupled Tokenizer and Multi-Scale Architecture for EEG Foundation Model - arXiv, otwierano: maja 18, 2026, <https://arxiv.org/html/2506.09110v4>
8. Understanding Vector Quantization in VQ-VAE - Hugging Face, otwierano: maja 18, 2026, <https://huggingface.co/blog/ariG23498/understand-vq>
9. BioSerenity-E1: a self-supervised EEG model for medical applications - arXiv, otwierano: maja 18, 2026, <https://arxiv.org/html/2503.10362v1>
10. Tokenizing Single-Channel EEG with Time-Frequency Motif Learning - arXiv, otwierano: maja 18, 2026, <https://arxiv.org/html/2502.16060v5>
11. EEG-to-Text Translation Models - Emergent Mind, otwierano: maja 18, 2026, <https://www.emergentmind.com/topics/eeeg-to-text-translation-models>
12. Large Language Models for Time Series: A Survey - IJCAI, otwierano: maja 18, 2026, <https://www.ijcai.org/proceedings/2024/0921.pdf>
13. BrainECHO: Semantic Brain Signal Decoding through Vector-Quantized Spectrogram Reconstruction for Whisper-Enhanced Text Generation - ACL Anthology, otwierano: maja 18, 2026, <https://aclanthology.org/2025.findings-acl.142.pdf>
14. amzn/sparse-vqvae: Experimental implementation for a sparse-dictionary based version of the VQ-VAE2 paper - GitHub, otwierano: maja 18, 2026, <https://github.com/amzn/sparse-vqvae>
15. Wojtekb30/llava-1.5-665k-instructions-Polish · Datasets at Hugging Face, otwierano: maja 18, 2026,

- <https://huggingface.co/datasets/Wojtekb30/llava-1.5-665k-instructions-Polish>
16. Utilizing Dry Electrode Electroencephalography and AI Robotics for Cognitive Stress Monitoring in Video Gaming - MDPI, otwierano: maja 18, 2026, <https://www.mdpi.com/2571-5577/7/4/68>
 17. DSI-Hybrid (Wearable Sensing) | NEUROSPEC, otwierano: maja 18, 2026, <https://www.neurospec.com/products/dsi-hybrid>
 18. Revolutionizing EEG, otwierano: maja 18, 2026, https://www.gnsinter.com/base/img/pro_img/Wearable-Sensing-DSI-7-Specificatio ns.pdf
 19. Comparative Results of Simultaneous Evoked Response Potential Measurements Using Dry Contact Electrodes and Conventional Wet Ele - Wearable Sensing, otwierano: maja 18, 2026, <http://ww.wearablesensing.com/files/Comparison%20of%20Simultaneous%20Dry %20and%20Wet%20Electrodes%20ERP.pdf>
 20. A multimodal gait dataset of brain activity, muscle activity, kinematics and ground forces in young adults - PhysioNet, otwierano: maja 18, 2026, <https://physionet.org/content/multimodal-gait-dataset/>
 21. DSI-Streamer - Wearable Sensing | Dry EEG, otwierano: maja 18, 2026, <https://wearablesensing.com/dsi-streamer/>
 22. DSI-Flex - Wearable Sensing | Dry EEG, otwierano: maja 18, 2026, <https://wearablesensing.com/dsi-flex/>
 23. NBackExample_imp.csv
 24. dsi-streamer, otwierano: maja 18, 2026, https://cdn.prod.website-files.com/67a2d0e30df3fc262c11071d/681069756675d90 ec63de9a9_DSI-Streamer_User%20Manual_v8.05.pdf
 25. dsi-24 User Manual, otwierano: maja 18, 2026, https://cdn.prod.website-files.com/67a2d0e30df3fc262c11071d/67f8bad12a46f2ffb 3bc31f9_DSI-24-Manual-V1.2023.pdf
 26. How EEG preprocessing shapes decoding performance - PubMed, otwierano: maja 18, 2026, <https://pubmed.ncbi.nlm.nih.gov/40640472/>
 27. Support - Wearable Sensing | Dry EEG, otwierano: maja 18, 2026, <https://wearablesensing.com/support/>
 28. Interpolate bad channels for MEG/EEG channels - MNE-Python, otwierano: maja 18, 2026, https://mne.tools/stable/auto_examples/preprocessing/interpolate_bad_channels.html
 29. Interpolating bad channels — MNE 0.21.2 documentation, otwierano: maja 18, 2026, https://mne.tools/0.21/auto_tutorials/preprocessing/plot_15_handling_bad_channels.html
 30. Rejecting bad data (channels and segments) — MNE 0.14.1 documentation, otwierano: maja 18, 2026, https://www.nmr.mgh.harvard.edu/mne/0.14/auto_tutorials/plot_artifacts_correction_rejection.html
 31. mne-python/mne/channels/tests/test_interpolation.py at main - GitHub, otwierano:

- maja 18, 2026,
https://github.com/mne-tools/mne-python/blob/master/mne/channels/tests/test_interpolation.py
32. Interpolation of bad channels in fNIRS data - Support & Discussions - MNE Forum, otwierano: maja 18, 2026,
<https://mne.discourse.group/t/interpolation-of-bad-channels-in-fnirs-data/4100>
 33. ECG-Based Detection of Epileptic Seizures in Real-World Wearable Settings: Insights from the SeizelT2 Dataset - PMC, otwierano: maja 18, 2026,
<https://pmc.ncbi.nlm.nih.gov/articles/PMC12736484/>
 34. Efficient Feature Extraction for EEG-Based Classification: A Comparative Review of Deep Learning Models - MDPI, otwierano: maja 18, 2026,
<https://www.mdpi.com/2673-2688/7/2/50>
 35. Virtual Electroencephalogram Acquisition: A Review on Electroencephalogram Generative Methods - PMC, otwierano: maja 18, 2026,
<https://pmc.ncbi.nlm.nih.gov/articles/PMC12116193/>
 36. hvEEGNet: a novel deep learning model for high-fidelity EEG reconstruction - PMC, otwierano: maja 18, 2026,
<https://pmc.ncbi.nlm.nih.gov/articles/PMC11695360/>
 37. A VQ-VAE framework for modeling physiological information in fMRI - NeurIPS 2026, otwierano: maja 18, 2026, <https://neurips.cc/virtual/2025/132654>
 38. Understanding Vector Quantized Variational Autoencoders (VQ-VAE) | by Shashank Yadav, otwierano: maja 18, 2026,
<https://medium.com/@shashank7-iitd/understanding-vector-quantized-variational-autoencoders-vq-vae-323d710a888a>
 39. Attentive VQ-VAE - arXiv, otwierano: maja 18, 2026,
<https://arxiv.org/html/2309.11641v2>
 40. EAD: An EEG Adapter for Automated Classification - arXiv, otwierano: maja 18, 2026, <https://arxiv.org/html/2505.23107v1>
 41. EEG Foundation Models: A Critical Review of Current Progress and Future Directions - arXiv, otwierano: maja 18, 2026, <https://arxiv.org/html/2507.11783v2>
 42. BrainRVQ: A High-Fidelity EEG Foundation Model via Dual-Domain Residual Quantization and Hierarchical Autoregression - arXiv, otwierano: maja 18, 2026,
<https://arxiv.org/html/2602.16951v1>
 43. Vector Quantization Pretraining for EEG Time Series with Random Projection and Phase Alignment - Xiucheng Li, otwierano: maja 18, 2026,
<https://xiucheng.org/assets/pdfs/icml2024-vq-mtm.pdf>
 44. Large Language Models for Time Series: A Survey - arXiv, otwierano: maja 18, 2026, <https://arxiv.org/html/2402.01801v3>
 45. Unsupervised EEG-Based Seizure Anomaly Detection with Denoising Diffusion Probabilistic Models - World Scientific Publishing, otwierano: maja 18, 2026,
<https://www.worldscientific.com/doi/pdf/10.1142/S0129065724500473?download=true>
 46. Virtual Electroencephalogram Acquisition: A Review on Electroencephalogram Generative Methods - MDPI, otwierano: maja 18, 2026,
<https://www.mdpi.com/1424-8220/25/10/3178>

47. GitHub - Wojtekb30/pyDirectMindwave: [WIP] A unofficial Python library for directly using the NeuroSky Mindwave Mobile 2 brainwave reader over Bluetooth, without the ThinkGear Connector app., otwierano: maja 18, 2026, <https://github.com/Wojtekb30/pyDirectMindwave>
48. mindwave-mobile2 · GitHub Topics, otwierano: maja 18, 2026, <https://github.com/topics/mindwave-mobile2?l=python>
49. Wojtekb30/Clipboard-saver - GitHub, otwierano: maja 18, 2026, <https://github.com/Wojtekb30/Clipboard-saver>
50. Wojtekb30/VideoCompressor: Compress a video file to a desired size in MB - GitHub, otwierano: maja 18, 2026, <https://github.com/Wojtekb30/VideoCompressor>
51. Wojtekb30/Discord-Bot-Pi-Pico-Display - GitHub, otwierano: maja 18, 2026, <https://github.com/Wojtekb30/Discord-Bot-Pi-Pico-Display>
52. Wojtekb30/Bielik-4.5B-v3.0-Instruct-Q6_K-GGUF · Hugging Face, otwierano: maja 18, 2026, https://huggingface.co/Wojtekb30/Bielik-4.5B-v3.0-Instruct-Q6_K-GGUF